

Roll No

CD-701 (GS)

B.Tech., VII Semester

Examination, June 2025

Grading System (GS)

Data Engineering

Time : Three Hours

Maximum Marks : 70

Note: i) Attempt any five questions.

किन्हीं पाँच प्रश्नों को हल कीजिए।

ii) All questions carry equal marks.

सभी प्रश्नों के समान अंक हैं।

iii) In case of any doubt or dispute the English version question should be treated as final.

किसी भी प्रकार के संदेह अथवा विवाद की स्थिति में अंग्रेजी भाषा के प्रश्न को अंतिम माना जायेगा।

1. a) Write short notes on different types and sources of data.

डाटा के विभिन्न प्रकारों और स्रोतों पर संक्षिप्त नोट्स लिखें।

b) Explain the importance of "Veracity" and "Value" in the five Vs of data and provide examples of how to enhance these elements in a data-driven approach.

डाटा के पाँच बनाव में सच्चाई और मूल्य के महत्व को समझाइए और डाटा-संचालित दृष्टिकोण में इन तत्वों को कैसे बढ़ाया जाए इसके उदाहरण प्रदान करें।

2. a) Explain the importance of securing data pipelines in the cloud.

क्लाउड में डाटा पाइपलाइनों को सुरक्षित करने के महत्व को समझाइए।

- b) Write a short note on data architecture on cloud platforms.
क्लाउड प्लेटफॉर्म पर डाटा आर्किटेक्चर पर एक संक्षिप्त नोट लिखें।

3. a) Discuss about data preparation's main steps including data discovery, cleaning, enrichment and validation.

डाटा खोज, सफाई, संवर्धन और सत्यापन सहित डाटा तैयारी के मुख्य चरणों के बारे में चर्चा करें।

- b) Write down the scaling issues of batch and stream ingestion techniques especially when working with IoT data.

विशेष रूप से IoT डाटा के साथ काम करते समय बैच और स्ट्रीम अंतर्ग्रहण तकनीकों के स्केलिंग मुद्दों को लिखें।

4. a) Explain the concept of big data processing and discuss the challenges associated with managing and processing large volumes of data.

बड़े डाटा प्रोसेसिंग की अवधारणा को समझाइए और बड़ी मात्रा में डाटा के प्रबंधन और प्रसंस्करण से जुड़ी चुनौतियों पर चर्चा करें।

- b) Describe the core components and architecture of Apache Hadoop and explain how it addresses these challenges through its distributed processing model.

Apache Hadoop के मुख्य घटकों और वास्तुकला का वर्णन करें और बताइए कि यह अपने वितरित प्रसंस्करण मॉडल के माध्यम से इन चुनौतियों का समाधान कैसे करता है।

- 5 a) Describe the importance of pre-processing and feature engineering in developing an effective ML model.

एक प्रभावी ML मॉडल विकसित करने में प्री-प्रोसेसिंग और फीचर इंजीनियरिंग के महत्व का वर्णन करें।

- b) What do you mean by the process of ingesting IoT data by stream and explain the key challenges involved in handling and processing real-time data from IoT devices.

स्ट्रीम द्वारा IoT डाटा को ग्रहण करने की प्रक्रिया से आपका क्या तात्पर्य है और IoT उपकरणों से वास्तविक समय के डाटा को संभालने और संसाधित करने में शामिल प्रमुख चुनौतियों की व्याख्या करें।

6. a) Explain how framing the ML problem to align with business goals influences the data collection and labeling process.

बताइए कि व्यावसायिक लक्ष्यों के साथ संरेखित करने के लिए ML समस्या को तैयार करना डाटा संग्रह और लेबलिंग प्रक्रिया को कैसे प्रभावित करता है।

- b) Compare the ETL and ELT approaches for data integration. डाटा एकीकरण के लिए ETL और ELT दृष्टिकोण की तुलना करें।

7. a) Explain the concept of data-driven decision-making and discuss how a well-designed data pipeline infrastructure supports effective decision-making in organizations.

डाटा-संचालित निर्णय लेने की अवधारणा को समझाइए और चर्चा करें कि कैसे एक अच्छी तरह से डिजाइन की गई डाटा पाइपलाइन संरचना संगठनों में प्रभावी निर्णय लेने में सहायता करती है।

- b) Draw and explain the ML infrastructure on AWS.

AWS पर ML इंफ्रास्ट्रक्चर बनाइए और समझाइए।

8. Write short notes on any two:

- a) Amazon EMR
- b) CI/CD
- c) Data Enriching and Data Validating
- d) AWS SageMaker

किन्हीं दो पर संक्षिप्त टिप्पणियाँ लिखें।

- अ) अमेजन EMR
- ब) CI/CD
- स) डाटा संवर्धन और डाटा सत्यापन
- द) AWS सेजमेकर